Sesión 3 ETL

DE LOS REGISTROS A LAS DECISIONES

Extraer datos. Construir información.

Convierte archivos dispersos en resultados fiables y automatiza el trabajo que se repite cada mes.

EL PROCESO QUE VAS A CONSTRUIR

01 · Doce archivos de origen
Ventas mensuales · CSV · datos sintéticos

02 · Un proceso automático
Leer → validar → limpiar → calcular

03 · Resultados verificables
Datos limpios, rechazos e informes

120 min	600.000	4 operaciones
Duración propuesta	Registros base del laboratorio	Filtrar · seleccionar · agregar · transformar

01 / RUTA DE APRENDIZAJE

De comprender el dato a procesarlo

Tras las bases del Big Data, pasamos a una pregunta práctica: **¿cómo obtener información útil a partir de los datos disponibles?** Al finalizar podrás distinguir niveles de interpretación, elegir una técnica de extracción y construir un proceso ETL sencillo con controles de calidad.

00–15 · Comprender
Dato, información y conocimiento

15–35 · Extraer
Fuentes, técnicas y ETL

35–55 · Operar
Cuatro operaciones esenciales

55–110 · Programar
Laboratorio con Python

110–120 · Explicar
Conclusiones y evaluación

Prerrequisitos: variables, listas, funciones y bucles básicos. El cuaderno guía cada paso e incluye soluciones orientativas.

---

02 / CONCEPTOS FUNDAMENTALES

Dato → información → conocimiento

REGISTRO

Dato

Una observación o representación: un número, una fecha, una etiqueta o un texto. Aislada puede resultar ambigua.

```
2025-06-10, web, 3, 2500
```

El esquema aporta significado: fecha, canal, unidades y precio unitario en céntimos.

CONTEXTO

Información

Datos organizados e interpretados para responder una pregunta, con unidad y periodo.

```
3 × 2500 = 7500 céntimos
Venta web: 75,00 €
```

El importe de esta operación ya tiene un significado que podemos comunicar.

INTERPRETACIÓN CONTRASTADA

Conocimiento

Comprensión que combina información, experiencia y evidencia para explicar o actuar.

Ejemplo hipotético: si una prueba controlada confirma que una mejora reduce abandonos, podemos decidir mantenerla.

Observar un aumento no demuestra su causa.

> **Idea clave:** agregar datos produce información; no garantiza conocimiento. Hay que comprobar la calidad, formular una pregunta y reconocer qué no podemos concluir.

▶ **Actividad · Clasifica estas afirmaciones**

---

03 / TÉCNICAS

Extraer es obtener; transformar es dar forma

La **extracción automática** recupera datos de una fuente mediante reglas ejecutables. También puede identificar campos dentro de contenido no estructurado. La **transformación** modifica estructura, tipos o valores para que puedan analizarse.

Elegir la técnica según la fuente y su estructura

Fuente	Técnica de extracción	Qué comprobar
CSV / Excel / JSON	Parser de archivos; lectura de hojas o campos	Separador, codificación, encabezados y tipos
Base de datos	Consultas SQL	Permisos, claves, nulos y consistencia temporal
API	Peticiones HTTP y lectura de JSON	Paginación, autenticación, límites y reintentos
Página HTML	Parser del DOM y selectores	Cambios de estructura y condiciones de acceso
Texto y logs	Expresiones regulares o extracción de entidades	Patrones, ambigüedad y falsos positivos

PDF escaneado o imagen	OCR y extracción posterior de campos	Calidad de imagen y errores de reconocimiento

ETL: extraer, transformar, cargar

E: leer archivos y conservar el origen.
T: convertir fechas, normalizar canales, separar errores y calcular importes.
L: guardar las tablas y los informes.

En ELT se carga antes de transformar, habitualmente para aprovechar la capacidad de un almacén de datos.

Automatización con control

Usa parámetros, comprueba el esquema, registra recuentos y falla de forma visible. Un precio ausente no debe convertirse silenciosamente en cero.

Un modelo de lenguaje puede ayudar con documentos variables, pero su salida necesita un esquema y validación.

▶ **Ejemplo · Extraer un código dentro de un texto**

▶ **Técnicas de transformación que conviene distinguir**

---

04 / OPERACIONES

Cuatro operaciones, cuatro preguntas

Operación	Pregunta	Ejemplo pandas
Filtrado	¿Qué filas cumplen una condición?	`df.loc[df['canal'].eq('web')]`
Selección	¿Qué columnas necesito?	`df[['id', 'canal', 'unidades']]`
Agregación	¿Qué resumen obtengo por grupo?	`df.groupby('canal')['unidades'].sum()`
Transformación	¿Qué valor debo convertir o calcular?	`df['importe'] = df['unidades'] * df['precio']`

calcular?

Aquí «selección» significa selección de columnas. En álgebra relacional, la selección suele referirse al filtrado de filas y la proyección a las columnas.

Experimenta con las operaciones

Miniatura de seis ventas sintéticas, independiente del conjunto Python. Primero filtramos, después calculamos el importe y, finalmente, agregamos.

Vista resultante

ID	Canal	Estado	Unidades	Precio unitario	Importe
1	web	completado	3	25,00 €	75,00 €
2	tienda	completado	2	18,00 €	36,00 €
4	web	completado	4	12,00 €	48,00 €
6	tienda	completado	1	65,00 €	65,00 €

4 de 6 operaciones · Suma: 224,00 € · Importe medio: 56,00 €

Si incluyes cancelaciones, la suma deja de representar solo ventas completadas. Seleccionar menos columnas no modifica las filas del filtro ni el total calculado.

> **No promedies medias sin comprobar los pesos.** Un grupo de 1 venta con ticket de 100 € y otro de 9 ventas con ticket de 10 € tienen un ticket global de (100 + 90) / 10 = **19 €**, no 55 €.

---

05 / LABORATORIO 1

Un año de ventas, un solo proceso

¿Cuál es el importe por mes y canal? ¿Qué proporción de registros no podemos utilizar?

600.000 registros · 12 archivos · Semilla 42

El cuaderno genera ventas sintéticas y añade 1.200 duplicados exactos. Introduce fechas inválidas, unidades negativas, precios ausentes y categorías con espacios o mayúsculas. No requiere descargar datos ni utilizar GPU.

Contrato de los datos

- Una fila = una operación de venta.
- `id` : identificador de operación.
- `fecha` : AAAA-MM-DD.
- `canal` y `estado` : categorías.
- `unidades` : entero positivo.
- `precio_centimos` : precio unitario en céntimos.
- `referencia` : texto con el SKU.

Resultados de la automatización

- `ventas_limpias.csv`
- `rechazados.csv` con motivo y origen
- `resumen_mensual.csv`
- `auditoria.json`
- `ventas_por_mes.png`
- `resultados_s03.zip`

1. **Preparar y generar · 10 min**
   Seleccionar kernel y crear los archivos reproducibles.

2. **Extraer e inspeccionar · 8 min**
   Recorrer archivos, comprobar esquema y conservar su origen.

3. **Transformar y validar · 12 min**
   Convertir tipos, extraer SKU y separar errores y duplicados.

4. **Filtrar y agregar · 10 min**
   Seleccionar ventas completadas y resumir por mes y canal.

5. **Automatizar y comprobar · 10 min**
   Ejecutar una función y repetir para verificar que los CSV no cambian.

6. **Interpretar y exportar · 5 min**
   Representar resultados, explicar límites y descargar el ZIP.

Opción A · Visual Studio Code

Instala Python 3.11 o posterior y las extensiones **Python** y **Jupyter** de Microsoft. Guarda el cuaderno y requirements.txt en una carpeta y ábrela en VS Code. En PowerShell:

```
py -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
```

Abre el cuaderno y elige **Seleccionar kernel** → **Entornos de Python** → **.venv**. Ejecuta en orden. El cuaderno incluye la variante para macOS/Linux.

Opción B · Google Colab

Descarga el .ipynb y usa **Archivo** → **Subir cuaderno** en Colab. El enlace anterior abre Colab; la subida es manual.

Usa CPU y ejecuta las celdas en orden. Si falta un paquete, utiliza la celda opcional de instalación. La instalación inicial requiere Internet.

Descarga el ZIP al terminar: los archivos de la máquina de Colab son temporales.

▼ **Resultados esperados con 50.000 registros por mes**

Control	Resultado esperado